



AUTOMATED END-TO- END DATA PIPELINE

for Online Retail Analytics



Data Source

- Online Retail II dataset dari Kaggle
- Format data CSV
- Dataset ini berisi histori transaksi e-commerce tahun 2010-2011 (500.000 transaksi)

Data Context

- Data mencakup: Invoice, StockCode, Description, Quantity, Price, Customer ID, Country, dan InvoiceDate
- Setiap baris merepresentasikan satu aktivitas pembelian pelanggan dari berbagai negara

Goal

- Membangun pipeline data end-to-end dari data mentah hingga siap analisis.
- Mengubah data menjadi data warehouse yang terstruktur dan konsisten.
- Menyediakan data untuk dashboard dan pengambilan keputusan bisnis otomatis.

Business Context & Problem

- Ada ketidakkonsistenan serta missing value.
- Data digunakan untuk analisis penjualan dan performa produk guna mendukung keputusan bisnis.

01 PROJECT OVERVIEW

Data Engineer Role in the Data Ecosystem (Online Retail Case)

01

Tantangan: Realitas Data Mentah



Missing CustomerID & Description

Banyak baris transaksi tidak memiliki ID pelanggan & Description (NULL), mempersulit analisis segmentasi perilaku.



Data Belum Konsisten

Banyak baris transaksi yang memiliki Price maupun Quantity < 0



Unusable State

Data mentah "kotor" ini tidak bisa langsung digunakan untuk dashboard Power BI atau analisis revenue

Masalah: Efisiensi yang Terhambat

80%
Waktu Terbuang

Pareto Principle

Tanpa proses engineering, analisis menghabiskan 80% waktu mereka hanya untuk manual data cleaning daripada melakukan analisis bisnis. Hal ini menyebabkan keterlambatan pengambilan keputusan dan insight yang berisiko tidak akurat.

Solusi: Pembagian Peran

Data Engineer

Membangun fondasi / pipeline :

- Data Cleaning
- Data Transformation
- Data Warehousing
- Quality Assurance



Data
Analysist-Ready

Data Analyst

Mengonsumsi data yang sudah bersih untuk membuat dashboard Power BI dan memberikan rekomendasi bisnis.



02 ETL VS ELT: STRATEGIC CHOICE

WORKFLOW

ETL ✓

Extract → Transform (In-Memory) → Load

Proses transformasi dilakukan sepenuhnya oleh Pentaho Data Integration sebelum menyentuh database

Data masuk ke MySQL sudah dalam keadaan bersih dan terstruktur (Star Schema)

Alur

Engine

Kondisi data

ELT

Extract → Load → Transform (In-Database)

Mengandalkan kekuatan Compute dari Database (SQL) untuk transformasi

Data mentah/kotor masuk dulu ke database, baru diproses kemudian

JUSTIFIKASI

Intensive Cleansing

ETL memungkinkan kami melakukan data cleansing secara mendalam agar tidak mengotori tabel utama di MySQL

Performance Implication

Karena volume data berukuran menengah, melakukan transformasi di memori Pentaho jauh lebih efisien

Storage Efficiency

Dengan ETL, tidak perlu menyiapkan tabel staging yang besar di MySQL untuk menampung data kotor

TOOL SELECTION & BUSINESS ALIGNMENT

03



MySQL: Pondasi Integritas Data

Menjamin konsistensi retail, karena integritas relasi antar entitas adalah prioritas utama dalam ekosistem retail yang kompleks.

- PK & FK: Memastikan setiap transaksi terhubung ke Produk dan Pelanggan yang valid.
- Data Integrity: Mencegah adanya "Orphan Records" dalam database.
- Skalabilitas: Performa optimal untuk query data historis transaksi.



Pentaho >> Akselerasi Development

Memungkinkan visualisasi logika ETL dan alur data secara grafis (drag-and-drop).

- Kecepatan: Mengurangi waktu coding manual hingga 50%.
- Transparansi: Logika bisnis mudah diaudit oleh non-developer.
- Maintenance: Modularitas workflow memudahkan perbaikan error.



04 DATA QUALITY & RELIABILITY >>>

Validasi & Monitoring



Validation

Pengecekan tipe data (format, fields) dan menggunakan condition Field IS NOT NULL.



Cleansing

Standardisasi format dengan trimming spasi, case reform, dan handling NULL.



Error Handling


Sistem mitigasi kegagalan dengan reject baris yang salah dan menyimpan log baris yang gagal.

Business Rules for Validation



Price Consistency

Validasi nilai Price > 0 untuk mencegah anomali data harga.



Schema Validation

Memastikan tipe data (integer, string, date) sesuai kontrak database target.



Boundary Check

Memastikan tanggal transaksi atau nilai numerik berada dalam rentang yang masuk akal (> 0, Min pada Pentaho).


Data Cleansing Strategies

Isu Data	Metode Cleansing	Dampak Bisnis
Quantity Negatif	Transformasi ke nilai absolut / 0	Akurasi stok barang
Missing Customer ID	Mapping ke 'Anonymous' / Default ID	Integritas data pelanggan
Duplikasi Transaksi	Deduplikasi berbasis ID Transaksi	Akurasi laporan pendapatan

PIPELINE ARCHITECTURE & LAYERS

03

ARSITEKTUR END-TO-END: TRANSFORMASI DATA MENTAH MENJADI BUSINESS INSIGHT



PIPELINE ARCHITECTURE & LAYERS

03

Source Layer



Online Retail Dataset
(2010-2011)

Layer 1: Source (External Data)

- Komponen: online_retail_11.csv
- Karakteristik: Data mentah (raw) hasil ekspor sistem transaksional retail yang masih mengandung duplikasi dan nilai anomali.

Ingestion


- CSV file input: Membaca dan mengekstrak data mentah dari CSV ke dalam aliran data transformasi
- Select values: memilih, menghapus, atau mengubah tipe data kolom agar sesuai dengan struktur tabel yang dituju
- Table output: Menyimpan hasil ingestion ke database OLTP
- Menggunakan metode batch ingestion dengan strategi full load (hanya pertama) dan incremental load (untuk update harian)



Ingest raw data ke OLTP database



CSV file input



Select values



Table output

PIPELINE ARCHITECTURE & LAYERS

03

Transformation 1

- Table Input: Mengambil data dari tabel raw.
- Unique Rows: Memastikan tidak ada data ganda (Deduplication).
- Filter Rows: Menerapkan business logic
- Calculator: Menambahkan fitur total_sales dari fitur Quantity x Price
- Table Output: Menyimpan tabel cleaned dalam OLTP database.


Business Logic

- Price > 0
- Quantity > 0
- CustomerID != NULL

Untuk menjaga akurasi pemeringkatan customer

Layer 2: Storage (Raw)

- Komponen: MySQL Database (retail_db.sql → OLTP database)
- Struktur: Masih berupa tabel 1NF




Storage Layer (Raw)



Derived Feature

Untuk meminimalkan beban komputasi (DAX) pada dashboard analitik.

03 DATA MODELING



Sales Fact

Tabel utama yang menyimpan data transaksi penjualan.
Tabel ini digunakan sebagai pusat analisis penjualan dan performa bisnis

Product Dimension

Menyimpan informasi produk
Digunakan untuk analisis performa produk dan penjualan.

Country Dimension

Menyimpan informasi negara asal transaksi pelanggan.
Digunakan untuk analisis penjualan berdasarkan wilayah atau negara.

Customer Dimension

Menyimpan informasi pelanggan.

Time Dimension

Menyimpan atribut waktu untuk kebutuhan analisis periodik.
Digunakan untuk analisis tren penjualan berdasarkan waktu.

Data Warehouse dirancang menggunakan star schema yang terdiri dari satu Fact Table dan beberapa Dimension Table. Struktur ini digunakan agar proses query dan analisis pada dashboard menjadi lebih cepat, terstruktur, dan mudah dipahami.

PIPELINE ARCHITECTURE & LAYERS

03


Mentransformasi data pelanggan dari tabel Cleaned menjadi tabel dimensi yang terstruktur, unik, dan siap dihubungkan dengan tabel fakta.

Transformation 2

- Table Input: Mengambil data dari tabel cleaned.
- Unique Rows: Memastikan setiap Customer ID hanya muncul satu kali dalam tabel dimensi
- Filter Rows: Memastikan tidak ada CustomerID yang NULL
- Dimension Lookup/Update: Menyimpan data ke dalam tabel dimensi final & Mengelola Surrogate Keys dan memperbarui data pelanggan secara otomatis.

 Penerapan konsep **Data Quality at Every Stage** dimana memastikan bahwa tabel dimensi 100% bersih sebelum kunci uniknya (Primary Key) digunakan oleh fact.

CUSTOMER DIMENSION




PIPELINE ARCHITECTURE & LAYERS

03

Transformation 3

- Extraction: Data ditarik melalui Table Input dari database operasional.
- Data Cleaning: String Operations dan Replace in String
- Deduplication: Menggunakan Unique Rows (HashSet)
- Quality Gate: Filter Rows menyaring data yang tidak relevan.
- Loading: Menggunakan Dimension Lookup/Update untuk sinkronisasi ke tabel final.

PRODUCT DIMENSION



1

- Trim Type (Both) pada kolom Description dan StockCode.
- Upper pada StockCode
- Remove Special Characters (horizontal tab)

2

Menghapus karakter koma (,) pada kolom Description agar tidak merusak format saat data diekspor atau diproses lebih lanjut.

3

- Exclusion of Non-Product Codes: POST, M agar tidak mengacaukan statistik performa produk.
- Completeness Check: * StockCode IS NOT NULL & Description IS NOT NULL

4

Data Routing: Data True dikirim ke tabel dimensi, sementara data yang tidak valid dikirim ke Dummy

5

Menggunakan SCD Type 2 untuk menjaga Integritas Historis.

PIPELINE ARCHITECTURE & LAYERS


03

COUNTRY DIMENSION



Table Output vs Dimension Update

- Bulk Insert jauh lebih cepat daripada metode Lookup/Update satu-per-satu, terutama untuk data wilayah yang bersifat statis.
- Menghindari beban komputasi lookup histori (SCD)



String Operations

- Menghapus spasi di awal dan akhir nama negara.
- Remove Special Character (spasi) yang tidak terlihat/anomali agar nama negara terstandarisasi.

Transformation 4

- Extraction: Mengambil kolom Country dari tabel Cleaned
- Unique Rows (HashSet): Menghapus duplikasi nama negara.
- Data Cleaning: String Operations
- Quality Gate: Filter Rows menyaring data yang tidak relevan.
- Loading: Menggunakan step Table Output untuk mengelola data ke dalam gudang data analitik (OLAP).

Filter Rows

Memastikan data yang tidak jelas atau kosong (Unspecified) dibuang ke step Dummy agar tidak mengotori laporan analitik.

PIPELINE ARCHITECTURE & LAYERS


03

Mentransformasi data transaksi dari tabel Cleaned menjadi tabel dimensi waktu yang terstruktur, unik, dan siap dihubungkan dengan tabel fakta.

Transformation 5

- Table Input: Mengambil data dari tabel cleaned.
- Unique Rows: Memastikan setiap tanggal hanya muncul satu kali dalam tabel dimensi
- Calculator: Ekstraksi otomatis Tahun, Bulan, Minggu, dan Hari dari kolom InvoiceDate.
- Modified JS Value: Scripting khusus untuk kalkulasi Quarter
- Table Output : Menjamin tabel dimensi waktu selalu sinkron dengan data transaksi harian dengan metode Truncate

TIME DIMENSION



Why?


- DateDim bersifat statis sehingga lebih efisien menggunakan Table Output
- Tidak memerlukan proses pengecekan perubahan data (lookup)



PIPELINE ARCHITECTURE & LAYERS

03

SALES FACT



Transformation 6

Data Integration (Inner Join): Menggunakan Inner Join untuk memastikan konsistensi data (Data Loss Prevention), menjaga integritas 390rb data transaksi asli.

Data Cleaning & Standardizing

- **Handling Nulls:** Mengganti nilai NULL menjadi -1 agar tetap konsisten dengan tabel dimensi.
- **Renaming:** Penamaan ulang kolom menjadi Total Sales untuk standarisasi laporan.
- **Quality Gate (Filtering):** Memvalidasi transaksi hanya untuk Quantity > 0 dan Price > 0.
- Data yang tidak valid dipisahkan ke **Dummy**.


Incremental Load Strategy

- **Group By (MAX):** Mencari tanggal transaksi terbaru sebagai referensi beban data berikutnya.
- **Add Constants:** Menambahkan ID konstan sebagai kunci unik (Primary Key) untuk tabel metadata.
- **Insert/Update:** Memperbarui tabel kontrol dengan Last Load Date terbaru agar proses ETL berikutnya berjalan secara otomatis dan efisien (hanya menarik data baru).

PIPELINE ARCHITECTURE & LAYERS

03

Data Loading



- **Definisi:** Tahap akhir dari siklus ETL di mana data yang telah melalui proses transformasi dipindahkan ke dalam Data Warehouse (DWH).
- **Target Output:** Data dimuat ke dalam struktur tabel **Fact dan Dimension** yang sudah disiapkan di database analitik.
- **Mekanisme Loading:** **Overwrite / Truncate** (Mengganti data lama menjadi terbaru) & **Incremental Load** (Hanya memasukkan data transaksi terbaru tanpa menghapus data lama)

Layer 3: Processing Layer

- **Platform Utama:** Menggunakan Pentaho Data Integration (PDI) sebagai mesin ETL (Extract, Transform, Load) utama.
- **Fungsi Strategis:** Bertindak sebagai jembatan logika yang menghubungkan Raw Storage (OLTP) dengan Data Warehouse (OLAP).
- **Batch Processing:** Mengolah data dalam jumlah besar secara berkala dari sumber file CSV dan Database MySQL.
- **In-Memory Processing:** Melakukan validasi dan kalkulasi data di dalam memori sebelum dialirkan ke tujuan akhir.
- **Tugas Utama:** Data Validation (menyaring anomali & null value), Dimensional Mapping (Memisahkan Fact dan Dimension), dan Data Integrity (FK terjaga)

- **Integritas Data (Data Constraints):** **Referential Integrity** (Memastikan setiap transaksi di tabel Fact memiliki referensi yang valid ke tabel Dimension) & **Foreign Key Validation** (Menjamin hubungan antar tabel tetap sinkron sesuai dengan desain Star Schema)
- **Tools:** Menggunakan step **Table Output** atau **Insert/Update** pada Pentaho Data Integration untuk menulis data ke MySQL.

PIPELINE ARCHITECTURE & LAYERS

03

Data Retrieval

Data Warehouse
(Fact & Dimension)




- **Definisi:** Proses pengambilan data dari Data Warehouse untuk dikonsumsi oleh lapisan penyajian (Serving Layer).
- **Connector Technology:** Menggunakan **MySQL Database Connector** untuk menjembatani DWH dengan Power BI Desktop.
- **Data Import Mode:** Mengambil seluruh data dari tabel Fact dan Dimension ke dalam In-Memory Cache Power BI untuk performa visualisasi yang cepat.

Layer 4: Storage (Data Warehouse)

- **Tujuan Utama:** Sebagai repositori pusat data yang telah divalidasi dan dioptimasi khusus untuk kebutuhan analisis (OLAP).
- **Teknologi:** Menggunakan MySQL Database sebagai Analytical Store.
- **Pemodelan Data:** Menerapkan Star Schema untuk menyederhanakan hubungan antar tabel dan mempercepat performa query.
- **Karakteristik:** Data bersifat **Persistent** (permanen), **Clean** (bersih), dan **Standardized** (terstandarisasi).

ORCHESTRATION

03




- Job ETL Data Warehouse digunakan untuk mengatur agar tabel dimensi diproses sukses sebelum tabel fakta (menjamin integritas data).
- Proses dimulai dari pemuatan tabel dimensi (CustomerDim, ProductDim, CountryDim, TimeDim) untuk membangun data referensi analisis
- Setelah seluruh dimensi selesai, data transaksi dimuat ke FactTable menggunakan surrogate key dari masing-masing dimensi
- Job diakhiri dengan status Success sebagai indikator seluruh proses ETL berjalan tanpa error

AUTOMATION

03

Proses menjalankan seluruh alur kerja data secara otomatis pada waktu yang telah ditentukan tanpa intervensi manual.

Komponen




Windows Task Scheduler

Trigger utama yang menjadwalkan waktu eksekusi



Kitchen (PDI)

Command-line tool yang bertugas mengeksekusi file Job (.kjb) di balik layar.



Batch Script (.bat)

Penghubung untuk menyiapkan environment (Setting Java JDK & Path)

Manfaat Utama

Consistency

Data selalu diperbarui tepat waktu secara konsisten.

Efficiency



Mengurangi beban kerja manual operasional.

Reliability

Memastikan ETL berjalan di background meskipun Spoon sedang ditutup.

```
Eksekusi Job Maria Theresa
[1] Setting Java JDK 25...
[2] Masuk ke Folder Launcher...
[3] Menjalankan Job...

2026-05-06 19:26:07.139 - Kitchen - Logging is at level : Basic
2026-05-06 19:26:07.151 - Kitchen - Start of run.
WARNING: A terminally deprecated method in sun.misc.Unsafe has been called
WARNING: sun.misc.Unsafe:objectFieldOffset has been called by com.google.common.util.concurrent.AbstractFuture$UnsafeAtomicHelper (file:/D:/Software/data-integration/launcher/.../lib/guava-32.1.2-jre.jar)
WARNING: Please consider reporting this to the maintainers of class com.google.common.util.concurrent.AbstractFuture$UnsafeAtomicHelper
WARNING: sun.misc.Unsafe:objectFieldOffset will be removed in a future release
2026-05-06 19:26:07.650 - Job 1 - Start of job execution
2026-05-06 19:26:07.674 - Job 1 - Starting entry [CustomerDim]
2026-05-06 19:26:07.861 - CustomerDim - Using run configuration [Pentaho local]
2026-05-06 19:26:07.873 - Carte - Installing timer to purge stale objects after 1440 minutes.
2026-05-06 19:26:07.875 - CustomerDim - Dispatching started for transformation [cust_dim]
2026-05-06 19:26:07.902 - Table output 2.0 - Connected to database [schema_star] (commit=1000)
2026-05-06 19:26:09.171 - Table input.0 - linenr 50000
2026-05-06 19:26:09.181 - Unique rows (HashSet).0 - Linenr 50000
2026-05-06 19:26:09.266 - Table input.0 - linenr 100000
2026-05-06 19:26:09.269 - Unique rows (HashSet).0 - Linenr 100000
2026-05-06 19:26:09.354 - Table input.0 - linenr 150000
2026-05-06 19:26:09.356 - Unique rows (HashSet).0 - Linenr 150000
2026-05-06 19:26:09.421 - Table input.0 - linenr 200000
2026-05-06 19:26:09.422 - Unique rows (HashSet).0 - Linenr 200000
2026-05-06 19:26:09.481 - Table input.0 - linenr 250000
2026-05-06 19:26:09.482 - Unique rows (HashSet).0 - Linenr 250000
2026-05-06 19:26:09.563 - Table input.0 - linenr 300000
2026-05-06 19:26:09.565 - Unique rows (HashSet).0 - Linenr 300000
2026-05-06 19:26:09.621 - Table input.0 - linenr 350000
2026-05-06 19:26:09.622 - Unique rows (HashSet).0 - Linenr 350000
2026-05-06 19:26:09.687 - Table input.0 - Finished reading query,
2026-05-06 19:26:09.691 - Unique rows (HashSet).0 - Finished processing (I=
2026-05-06 19:26:09.695 - Filter rows.0 - Finished processing (I=
2026-05-06 19:26:09.704 - Table input.0 - Finished processing (I=
2026-05-06 19:26:09.847 - Table output 2.0 - Finished processing
2026-05-06 19:26:09.852 - Job 1 - Starting entry [ProductDim]
2026-05-06 19:26:09.923 - ProductDim - Using run configuration [P
2026-05-06 19:26:09.926 - ProductDim - Dispatching started for tr
2026-05-06 19:26:09.938 - Table output.0 - Connected to database
2026-05-06 19:26:10.242 - Table input.0 - linenr 50000
2026-05-06 19:26:10.286 - Unique rows (HashSet).0 - Linenr 50000
```



PIPELINE ARCHITECTURE & LAYERS

03


Serving Layer



Microsoft Power BI

Layer 5: Serving (Analytics)

- Komponen: Power BI
- Output: Dashboard interaktif untuk monitoring performa penjualan



- https://app.powerbi.com/links/99-cEtbam3?ctid=3485b963-82ba-4a6f-810f-b5cc226ff898&pbi_source=linkShare

04


DATA CONSUMPTION: SERVING INSIGHT

Tren Pendapatan Positif: Pertumbuhan penjualan yang terus meningkat secara konsisten sejak akhir 2010 hingga akhir 2011.

Produk Andalan **Paper Craft** menjadi **kontributor profit terbesar** yang mendominasi hampir 28% dari total pendapatan 5 produk teratas.

Pola Penjualan: Mayoritas transaksi merupakan pesanan retail skala kecil, dengan beberapa pesanan besar sebagai pengecualian (outliers).

Jangkauan Pasar: Bisnis memiliki jejak distribusi yang luas di wilayah strategis global, terutama di Benua Eropa (UK sebagai negara dengan customer terbanyak).



04

DATA CONSUMPTION: SERVING INSIGHT

Retail Customer Cohort Analysis



Customers


Customers
Retained

Average Spend


Customers by Cohort and Months after first purchase

Cohort Month	0	1	2	3	4	5	6	7	8	9	10	11	12	Total
December 2010	885	885	885	885	885	885	885	885	885	885	885	885	885	885
January 2011	416	416	416	416	416	416	416	416	416	416	416	416		416
February 2011	380	380	380	380	380	380	380	380	380	380	380			380
March 2011	452	452	452	452	452	452	452	452	452	452				452
April 2011	299	299	299	299	299	299	299	299						299
May 2011	283	283	283	283	283	283	283							283
June 2011	242	242	242	242	242	242								242
July 2011	185	185	185	185	185									185
August 2011	169	169	169	169										169
September 2011	299	299	299											299
October 2011	357	357												357
November 2011	323													323
December 2011	41													41
Total	4339	4339	4339	4339	4339	4339	4339	4339	4339	4339	4339	4339	4339	4339


Customer Value vs Frequency



Spending Trends by Month



Avg Revenue per Customer by Country



New Customers Count and Existing Customers Count by Year and Month



Lonjakan Musiman (Q4 Peak): Terdapat kenaikan total belanja (Total Spend) yang sangat signifikan pada bulan November.

Kesehatan Retensi Pelanggan: Grafik New vs Existing Customers menunjukkan pertumbuhan basis pelanggan lama yang stabil

Anomali Belanja: Terjadi lonjakan rata-rata belanja yang luar biasa pada Cohort Mei 2011 di bulan ke-7 (\$235.51), yang jauh melampaui rata-rata normal grup lainnya.

Konsistensi Rata-rata Belanja: Meskipun total volume belanja berfluktuasi secara bulanan, garis Average Spend cenderung stabil

04

DATA CONSUMPTION: SERVING INSIGHT


Dominasi Pasar Internasional: Belanda merupakan pasar dengan nilai rata-rata pesanan tertinggi, menyumbang sebesar 26,63% dari total kategori pasar bernilai tinggi.

Produk "**Paper Craft Little Birdie**" menjadi produk paling sukses karena memimpin baik dalam rata-rata nilai penjualan per pesanan maupun total volume kuantitas.

Retensi Penjualan Pasca Pembelian: Terjadi penurunan drastis pada total penjualan setelah bulan pertama, namun angka tersebut cenderung stabil di kisaran 0.5M hingga bulan ke-11.

Fast-Moving Products: Menampilkan 10 produk yang paling banyak keluar dari gudang berdasarkan jumlah yang terjual.

Retail Product Sales Analysis 🏷️



CONCLUSION



Proyek ini berhasil membangun ETL (Extract, Transform, Load) pipeline pada dataset Online Retail Sales untuk mengelola data dari tahap pengambilan, pembersihan, transformasi, hingga penyimpanan ke dalam data warehouse. Proses transformasi dilakukan dengan membersihkan data, menghapus duplikasi, serta membentuk struktur star schema menggunakan tabel dimension dan fact agar data lebih terorganisir dan mudah dianalisis. Hasil implementasi menunjukkan bahwa ETL pipeline mampu meningkatkan kualitas, konsistensi, dan efisiensi pengelolaan data sehingga dapat mendukung proses analisis bisnis dan pengambilan keputusan berbasis data secara lebih efektif.



THANK YOU



07



ATTACHMENT

LINK PPT (Transform – Consumption) :

<https://canva.link/hl7hpgc81h0yjdj>

LINK POWERBI

https://app.powerbi.com/links/99-cEtbam3?ctid=3485b963-82ba-4a6f-810f-b5cc226ff898&pbi_source=linkShare